Progetto di Text Mining

Wish Upon a Star: predirre il sentiment di una review dal suo contenuto.

- Lorenzo Camaione 850380
- Davide Toniolo 800458
- Università degli Studi di Milano-Bicocca

Introduzione

- Gli obiettivi
- Dataset
- Text preprocessing
- Modelli a confronto
- Conclusioni

Gli obiettivi

E’ possibile predirre il sentiment di una review dal suo testo?

Dataset

Esplorazione

280 000 review in formato JSON – Ambito Clothing, Shoes and Jewellery

Filtro dei campi interessanti

Discretizzazione della variabile target:

- 1-2 stelle: sentiment negativo
- 3 stelle: sentiment neutro
- 4-5 stelle: sentiment positivo

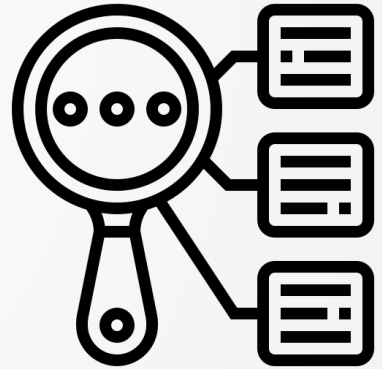

Esplorazione delle review con 1 e 5 stelle tramite uso di word cloud

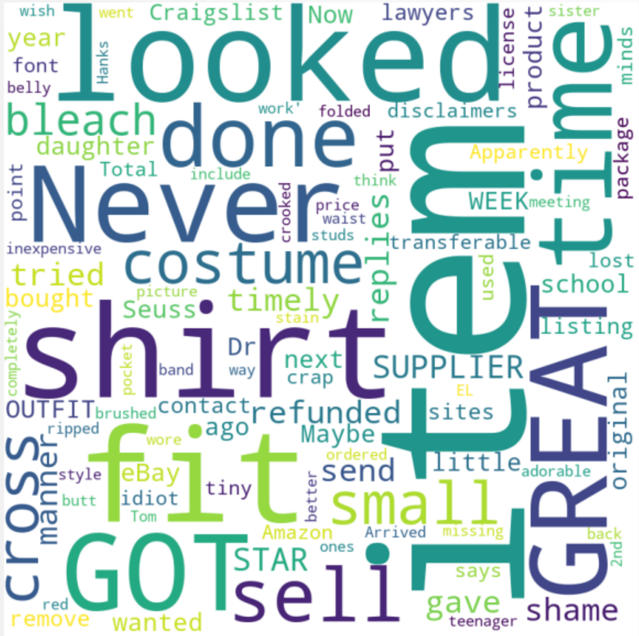

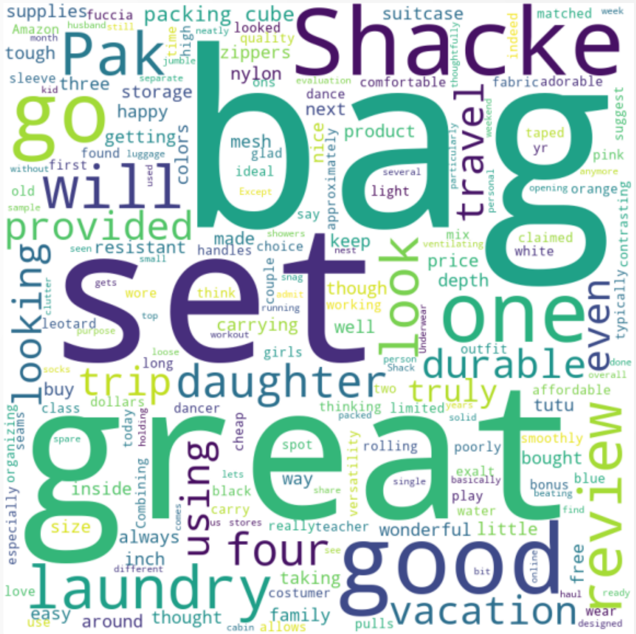

Text preprocessing | **Text representation** | **Ottimizzazione**

- Tokenization
- Normalization
- Stemming o lemmatization
- Stop words removal

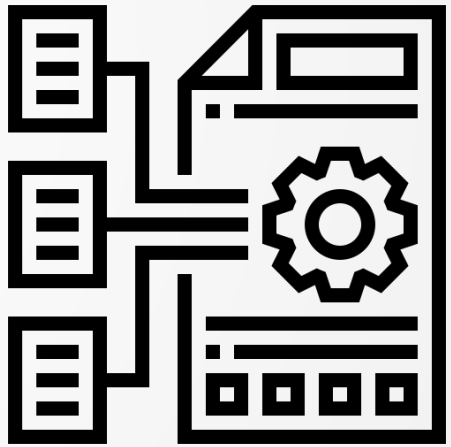

Text preprocessing

Text representation

Ottimizzazione

- Bag of words
- Tf-idf

- Ottimizzazione dell’utilizzo di memoria
- Matrici Sparse
- Decomposizione usando PCA

Modelli

- Gaussian NB
- Reti neurali
- Knn
- Random forest
- Linear SVC

Confronto tra modelli

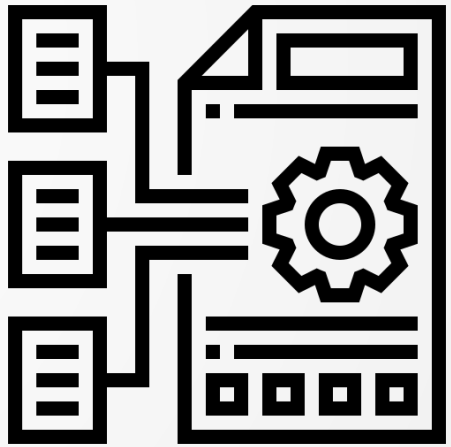

Performance dei vari modelli misurati in termini di precision e recall

	Metric	Gaussian NB	Random Forest	kNN	Linear SVM	ANN
Class 0	Precision	0.18	0.75	0.24	0.32	0.37
	Recall	0.74	0.10	0.34	0.84	0.82
	F1-measure	0.28	0.18	0.28	0.46	0.51
Class 1	Precision	0.95	0.90	0.84	0.98	0.97
	Recall	0.58	1.00	0.87	0.79	0.83
	F1-measure	0.72	0.95	0.86	0.87	0.90
Macro Avg	Precision	0.56	0.82	0.43	0.65	0.67
	Recall	0.66	0.55	0.43	0.81	0.83
	F1-measure	0.50	0.56	0.42	0.67	0.70
Accuracy		60%	90%	73%	79%	83%

Conclusioni e Sviluppi Futuri

Conclusioni e Sviluppi Futuri

- I modelli di tipo Random Forest e Fully Connected NN hanno i risultati i più promettenti
- Utilizzare altre tecniche per la Fattorizzazione
- Esplorare rappresentazioni testuali più sofisticate

Grazie per l’attenzione!